

233

Analyse numérique Matricielle.

Résolution approchée de systèmes linéaires, recherche d'éléments propres.

Ref: [F.C.] F. Clot, Analyse numérique

[Cia] Lienker, Analyse numérique matricielle et optimisation

Ref: [F.C.] F. Clot, Analyse numérique, le calcul scientifique.

Dev: 19

Convergence méthode itératives (+ Mandelbrot)

28 Gradient à pas optimal.

[Cia]

[F.C.] 9

[Qua] 10 24

Cache: On se place dans  $k = \mathbb{R}$  ou  $\mathbb{C}$ , pour  $m \in \mathbb{N}^*$ I. Normes matricielles et conditionnement.1) Normes matriciellesDef 1: On appelle norme matricielle une norme sur l'espace vectoriel  $M_n(K)$ . On dit qu'une norme  $\|\cdot\|$  est sous-multiplicative si

$$\forall A, B \in M_n(K), \|AB\| \leq \|A\| \|B\|.$$

Def 2: Pour  $\|\cdot\|$  une norme sur  $K^m$ , l'application  $\|\cdot\|$  de finie sur  $M_n(K)$  par

$$\|A\| = \sup_{x \neq 0} \frac{\|Ax\|}{\|x\|} = \sup_{\|x\|=1} \|Ax\|$$
 de finie une norme sur  $M_n(K)$ , dite norme matricielle subordonnée à la norme l.l.

Prop 3: Une norme matricielle subordonnée (NMS) est une norme matricielle sous-multiplicative.

Ex 4: Si  $\|\cdot\|$  est une NMS sur  $\mathbb{R}^m$ ,  $\|A\| = \sup_{j=1, \dots, m} \sum_{i=1}^m |a_{ij}|$ .

Ex 5: Toutes les normes matricielles ne sont pas sous-multiplicatives.

Ex:  $\|A\|_1 = \sup_j \sum_i |a_{ij}|$ , alors pour  $A = \begin{pmatrix} 1 & 1 \\ 1 & 1 \end{pmatrix}$ ,  $\|A\|_1 = 2 > \|A\|_1 \|A\|_1 = 1$ .

En particulier, il existe des normes non subordonnées à une norme vectorielle.

Def Prop 6: Pour  $A \in M_n(K)$ , on définit  $\rho(A)$  le rayon spectral de  $A$  comme le sup des modules de ses valeurs propres. La norme subordonnée à la norme euclidienne (hermitienne) est alors donnée par

$$\|A\|_2 = \sqrt{\rho(A^*A)} \text{ où } A^* \text{ est l'adjoint de } A. \quad (*)$$

2) Conditionnement d'une matrice.Def 7: Soit  $A \in GL_n(K)$ , on définit le conditionnement de  $A$  relativement à une norme subordonnée  $\|\cdot\|$  le nombre  $K(A) = \|A\| \|A^{-1}\|$ .

Le conditionnement permet de mesurer la sensibilité de la solution d'un système linéaire à la condition initiale:

Si  $x$  est solution de  $Ax=b$ , et  $x+\delta x$  est solution de  $A(x+\delta x)=b+\delta b$  alors  $\frac{\|\delta x\|}{\|x\|} \leq K(A) \frac{\|\delta b\|}{\|b\|}$ . Si  $K(A)$  est grand, l'erreur relative en  $b$ peut induire une grande erreur en  $x$ . On parle alors de système mal conditionné.Théor 8 (Housholder) Si  $\|\cdot\|$  est une NMS, alors  $\|A\| \geq \rho(A)$ , et pour

$$\varepsilon > 0, \exists \|A\|_K A \text{ telle que } \|A\|_K A \leq \rho(A) + \varepsilon$$

Ex 9: La matrice de Hilbert est mal conditionnée.

Prop 10: Pour  $A \in GL_n(K)$ , on a  $K(A) = K(A^{-1}) \geq 1$ ,  $K(I_n) = 1$  et  $K(AA) \neq 1$ Prop 11: On ne peut pas améliorer le conditionnement par une simple multiplication scalaire. Il faut multiplier à gauche par une matrice bien choisie (idéalement  $A^{-1}$ , mais bien sûr pas pratique, on doit être plus subtil).Prop 12: Si  $A$  est hermitienne, alors  $\|A\|_2 = \rho(A)$ . De plus si  $A$  admet des valeurs propres croissantes, alors  $K(A) = \lambda_m / \lambda_1$ .II. Méthodes directes de résolution des systèmes linéaires.1) Méthode de Gauss.

On se ramène dans tous les cas à l'étude de systèmes triangulaires "rapides" à résoudre par descente et remontée.

Pour un système  $Ax=b$  où  $A=(a_{ij})$ , on considère les opérations suivantes.→ Choisir une ligne de  $A$  telle que  $a_{ii} \neq 0$ .

→ Echanger la ligne en question avec la première.

→ Remplacer les lignes 2 → m par  $\ell_i = a_{i1} - \frac{a_{i1} a_{11}}{a_{11}}$ → Répéter sur la sous-matrice  $(a_{ij})_{i,j \geq 2}$ .

On termine cet algorithme avec une système triangulaire supérieure.

Mais on peut avoir des problèmes de stabilité des p.v.

2) Factorisation LU.Théor 13: Soit  $A \in GL_n(K)$  telle que toutes les sous-matrices principales de  $A$  soient inversibles, il existe un unique couple  $(L, U)$  constitué d'une matrice  $n \times n$  inf à diagonale unité, et d'une matrice triangulaire supérieure, tel que  $A=LU$ .Cor 14:  $A \in S_m^{++}(\mathbb{R})$  admet une décomposition LU.Ex 15: Si  $A$  est  $n$ -diagonale  $a_1, \dots, a_n, b_1, \dots, b_m, c_1, \dots, c_{m-1}$ , on définit

$$\delta_0 = 1, \delta_1 = b_1, \delta_{k+2} = b_{k+2} \delta_{k+1} - a_{k+2} c_{k+1} \delta_k, k \geq 0.$$

Si tous les  $\delta_k$  sont différents de 0, la factorisation LU de  $A$  est

$$\begin{pmatrix} \delta_0 & & & 0 \\ a_{12} & \delta_1 & & 0 \\ & a_{22} & \delta_2 & \\ & & & \ddots \\ & & & & \delta_{m-1} \end{pmatrix} \begin{pmatrix} c_1 & & & 0 \\ & \delta_1 & & 0 \\ & & \delta_2 & \\ & & & \ddots \\ & & & & \delta_{m-1} \end{pmatrix}$$

Ex 16: Réduction de la matrice des Laplacien discret.

Méthode de calcul d'une décomposition LU: Méthode de Doolittle.

Pour  $h=1:m$  pour

$$u_{hj} = a_{hj} - \sum_{k=1}^{h-1} l_{hk} u_{kj} \quad l_{ih} = \frac{1}{u_{hh}} \left( a_{ih} - \sum_{k=1}^{h-1} l_{ik} u_{hk} \right)$$

[F.C.]

[Qua]



[F:2]  
2729

### 3) Factorisation de Cholesky

Théorème 17: Soit  $A \in \mathbb{R}^{n \times n}$  hermitienne (symétrique) définie positive. Alors il existe une matrice  $R$  triangulaire supérieure telle que  $R^* R = A$ . Si on impose les coefficients diagonaux de  $R$  égaux à 1, alors la factorisation est unique.

Méthode de calcul:  $h_{11} = \sqrt{a_{11}}$ , pour  $i = 2 : n$ , faire  
 $h_{ij} = \frac{1}{h_{jj}} (a_{ij} - \sum_{k=1}^{j-1} h_{ik} h_{jk})$   $j \in \{1, \dots, i-1\}$ .  $-h_{ii} = (a_{ii} - \sum_{k=1}^{i-1} h_{ik} h_{ik})^{1/2}$

On obtient ainsi:  $R^*$

Ex 18:  $\begin{pmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{pmatrix} = \begin{pmatrix} \sqrt{2} & 0 & 0 \\ \frac{-1}{\sqrt{2}} & \sqrt{2} & 0 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & \sqrt{2} \end{pmatrix}$

### III. Méthode itératives de résolution des systèmes linéaires.

On se donne un système linéaire  $Ax=b$ , à résoudre. On cherche une suite  $x^m$  de  $\mathbb{R}^n$  qui converge vers la solution. On peut relier ce problème à un problème de minimisation. Si  $A \in S_n^{++}(\mathbb{R})$ , la fonctionnelle quadratique  $J(x) = \frac{1}{2} (Ax, x) - (b, x)$  admet un unique minimum qui se trouve être la solution du système. Ses méthodes que nous allons présenter ont des analogues en optimisation.

#### 1) Généralités.

On se ramène à résoudre  $u = Bu + c$  où  $(I - B) \in GL_n(\mathbb{K})$  est telle que la solution de ce dernier système soit également la solution de  $Au=b$ . On va alors tenter d'appliquer un algorithme de point fixe et de poser

$$u_{m+1} = Bu_m + c.$$

la partie résidant dans le choix de la matrice  $B$  et du vecteur  $c$ .

Théorème 19: On a équivalence entre.

- i) la méthode (M) converge
- ii)  $\rho(B) < 1$
- iii)  $\|B\| < 1$  par au moins une norme matricielle sub II.1.

Rq 20: La convergence est géométrique et induit par  $\rho(B)$  (au p. 10).

#### 2) Méthodes itératives classiques.

On suppose ici pouvoir écrire  $A$  sous la forme  $M - N$  où  $M \in GL_n(\mathbb{K})$  est 'facile' à inverser (symétrique,  $M$  diagonale ou triangulaire). On a alors

$$Au=b \Leftrightarrow Mu = Nu + b \Leftrightarrow u = M^{-1}(Nu + b) = M^{-1}Nu + M^{-1}b. \text{ D'où la méthode}$$

$$u_{k+1} = M^{-1}Nu_k + M^{-1}b, \text{ correspondant à } B = M^{-1}N = I - M^{-1}A. \text{ On remarque d'ailleurs que } I - B = M^{-1}A \text{ est inversible.}$$

[Cia]  
97-100

Notation: Pour  $A \in GL_n(\mathbb{K})$ , on pose  $D$  la partie diagonale,  $-E$  et  $F$  ses parties triangulaires inférieures et supérieures strictes (respectivement) de sorte que  $A = D - E - F$

Méthode de Jacobi: on pose  $M = D$  (donc  $N = E + F$ ), on obtient la méthode itérative

$$Du_{k+1} = (E + F)u_k, \text{ la matrice correspondante est } J = D^{-1}(E + F).$$

Méthode de Gauss-Seidel On prend  $M = D - E$ , donc on travaille avec la matrice

$$L_1 = (D - E)^{-1}F, \text{ dite matrice de Gauss-Seidel.}$$

Méthode de relaxation: On introduit un paramètre  $\omega$ , dit de relaxation et on pose

$$M = \frac{D}{\omega} - E, \text{ on a donc la matrice d'itération } \omega L = (\frac{D}{\omega} - E)^{-1}(\frac{1-\omega}{\omega}D + F).$$

on pourra alors chercher le meilleur paramètre  $\omega$  par minimisation de  $\rho(\omega L)$ .

Théorème 21: Si  $A$  est hermitienne définie positive,  $A = M - N$  où  $M \in GL_n(\mathbb{K})$ . Alors si  $M^* + N$  est définie positive, on a  $\rho(M^{-1}N) < 1$

Théorème 22: Si  $A$  est hermitienne définie positive, la méthode de relaxation converge pour  $\omega \in ]0, 2[$  (en particulier, Gauss-Seidel converge).

Théorème 23: On a l'inégalité  $\rho(\omega L) \geq |\omega - 1|$ ,  $\omega \neq 0$ . Ainsi la méthode de relaxation ne peut converger que pour  $\omega \in ]0, 2[$ .

Théorème 24: Si  $A$  est tridiagonale par blocs. On a  $\rho(\omega L) = \rho(J)$ : les méthodes de Jacobi et de Gauss-Seidel convergent donc simultanément, et si elles convergent, la méthode de Gauss-Seidel converge plus rapidement.

Si  $A$  est plus hermitienne définie positive. Alors le paramètre de relaxation optimal est  $\omega = 2 / (1 + \sqrt{1 - \rho(J)})$  si  $\rho(J) > 0$ , et 1 si  $\rho(J) = 0$

#### 3) Méthodes d'optimisation: (concl.)

On considère  $J: X \rightarrow \mathbb{R}$  (uniquement une fonctionnelle quadratique), supposez une fonctionnelle  $\phi$ -convexe (matrice  $B^{++}(\mathbb{R})$ ). On construit des méthodes itératives sous la forme  $x^{m+1} = x^m + p^m d^m$  ( $p^m$  est le pas,  $d^m$  la direction).

Méthode de relaxation: On prend successivement  $d^m$  les vecteurs de base canoniques.

Etant donné  $x^m \in \mathbb{R}^n$ , on pose, pour  $i \in \{1, \dots, n\}$   $x_i^{m+1} \in \mathbb{R}$  minimisant la fonction

$$t \mapsto J(x_1^m, \dots, x_{i-1}^m, t, x_{i+1}^m, \dots, x_n^m), \text{ on pose ensuite } x^{m+1} = (x_1^{m+1}, \dots, x_n^{m+1})$$

Théorème 25: Si  $J$  est une fonctionnelle elliptique ( $A$  est définie positive). Alors la méthode de relaxation converge.

Rq 26: C'est en fait la méthode de Gauss-Seidel appliquée au système linéaire correspondant.

[Cia]  
97106

[Cia]  
186



[Cia]  
189  
192.

On peut également prendre  $\nabla J(x^m)$  comme direction, ce qui donne les méthodes de gradient dont la liberté réside dans le choix du pas.

Gradient à pas fixe:  $p = p^m$  est constant.

Gradient à pas optimal:  $p^m$  est choisi pour minimiser  $p \mapsto J(x^m - p \nabla J(x^m))$ .

Théor 27: Si  $J$  est d-convexe, et  $\nabla J$  est L-lipschitzien, alors pour  $p \in ]0, \frac{2}{L}]$ , la méthode de gradient à pas fixe converge.

Théor 28: Si  $J$  est d-convexe, alors la méthode du gradient à pas optimal converge AP.

Prop 29: L'encadrement du théorème 27 n'est pas optimal, pour une fonctionnelle quadratique on peut aller jusqu'à  $\frac{2}{\lambda_m}$  au lieu de  $\frac{2\lambda_1}{\lambda_m}$  (le pas fixe optimal est  $\frac{2}{\lambda_1 + \lambda_m}$ ).

Prop 30: Le pas optimal peut en général être coûteux à calculer, mais pour une fonctionnelle quadratique, c'est explicite et donné par  $\frac{(b^T A^{-1} b)}{(A^{-1} 1, 1)}$  où  $n^h = A x^h - b$ .

#### IV. Problèmes aux valeurs propres.

On cherche ici à trouver, étant donnée une matrice  $A$ ,  $\lambda \in \sigma(A)$  et  $v \neq 0$  ( $Av = \lambda v$ ).

Théor 31 (Gerschgorin): Soit  $A \in M_n(\mathbb{C})$ , posons  $A = (a_{ij})_{i,j \in \{1, \dots, n\}}$ , pour  $i \in \{1, \dots, n\}$ , on pose  $D_i$ : le disque complexe (fermé) de centre  $a_{ii}$  et de rayon  $\sum_{j \neq i} |a_{ij}|$ , c'est le  $i$ -ème disque de Gerschgorin. On a  $\sigma(A) \subseteq \bigcup_{i=1}^n D_i$ .

Prop 32: Le résultat donne une première approximation des racines d'un polynôme en fonction de ses coefficients (par les matrices compagnon).

Prop 33: Une matrice à diagonale strictement dominante est trivialement inversible.

#### 1) Méthode de la puissance.

On a donné les valeurs propres de  $A$  (avec multiplicité) par leur module:  $|\lambda_1| \leq \dots \leq |\lambda_m|$ . On suppose  $|\lambda_m| > |\lambda_{m-1}|$  (valeur propre dominante). On considère la méthode

$$A x^{k+1} = x^k, \quad x^{k+1} = \frac{x^k}{\|x^k\|}.$$

La dernière condition est tout la divergence de la méthode.

Théor 34: Si  $A \in M_n(\mathbb{C})$  est diagonalisable,  $x_0 \notin \text{Ker}(A - \lambda_m \text{Id})$ , alors la suite  $(x_n)$  définie ci-dessus converge vers un vecteur propre associé à la valeur propre  $\lambda_m$ . En outre la suite  $(\|A x^k\|)$  ou  $(\|x^k\|)$  converge vers  $|\lambda_m|$ .

Prop 35: En appliquant cette méthode à  $A^{-1}$  (invariant de systèmes linéaires) on peut retrouver la plus petite valeur propre de  $A$ . (Et même toutes les valeurs propres (puissance inverse sur  $(A - \lambda \text{Id})$ ).

#### 2) Méthode de Jacobi.

Soit  $A \in M_n(\mathbb{R})$  symétrique. La méthode de Jacobi consiste à construire une suite  $(Q_k)$  de matrices orthogonales "élementaires" telle que la suite de

[Qua]  
168.

[Fi]  
66  
68

[Qua]  
172.

[Cia]  
111  
117

$A_{k+1} = Q_k^T A_k Q_k = Q_1^T \dots Q_k^T A Q_1 \dots Q_k$   $k \geq 1$  converge vers la matrice  $\text{diag}(\lambda_1, \dots, \lambda_m)$  où  $\{\lambda_i\} = \sigma(A)$  et telle que la suite  $O_k = Q_1 \dots Q_k$  converge vers une matrice orthogonale dont les colonnes forment une base orthonormée de vecteurs propres de  $A$ .

Théor 36: Soient  $1 \leq p < q \leq m$  et  $\theta \in \mathbb{R}$ . On pose

$$Q := \begin{pmatrix} 1 & & & \\ & \cos \theta & & \sin \theta \\ & & 1 & \\ & -\sin \theta & & \cos \theta \\ & & & & 1 \end{pmatrix}$$

1) Si  $A$  est symétrique, alors  $B = Q^T A Q$  est symétrique et  $\sum b_{ij}^2 = \sum a_{ij}^2$ .

2) Si  $a_{pq} \neq 0 \exists! \theta \in ]-\frac{\pi}{4}, \frac{\pi}{4}] \setminus \{0\}$  |  $b_{pq} = 0$ . C'est la solution de  $\cotan(2\theta) = \frac{a_{qq} - a_{pp}}{2a_{pq}}$  et  $\sum b_{ij}^2 = \sum a_{ij}^2 + 2a_{pq}^2$ .

Lemme 37: Soit  $X$  un espace vectoriel normé de dimension finie  $(x_n)$  une suite bornée de  $X$  admettant un nombre fini de valeurs d'adhérence et telle que  $\lim \|x_{n+1} - x_n\| = 0$  converge.

Théor 38: La suite  $(A_k)$  définie ci-dessus converge et  $\lim A_k = \text{diag}(\lambda_1, \dots, \lambda_m)$  où  $\sigma \in \sigma_m$ .

Théor 39: On suppose que les valeurs propres de  $A$  sont distinctes. Alors la suite  $(O_k)$  définie ci-dessus converge vers une matrice orthogonale dont les colonnes forment une base orthonormée de vecteurs propres de  $A$ .